

**VYSOKÉ UČENÍ TECHNICKÉ V BRNĚ**  
BRNO UNIVERSITY OF TECHNOLOGY

**FAKULTA INFORMAČNÍCH TECHNOLOGIÍ  
ÚSTAV POČÍTAČOVÝCH SYSTÉMŮ**

FACULTY OF INFORMATION TECHNOLOGY  
DEPARTMENT OF COMPUTER SYSTEMS

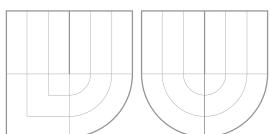
## **ANONYMIZACE SPZ VOZIDEL ZACHYCENÝCH NA FOTOGRAFIÍCH**

**DIPLOMOVÁ PRÁCE**  
MASTER'S THESIS

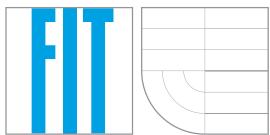
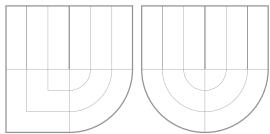
**AUTOR PRÁCE**  
AUTHOR

Bc. BARBORA SKŘIVÁNKOVÁ

BRNO 2016



VYSOKÉ UČENÍ TECHNICKÉ V BRNĚ  
BRNO UNIVERSITY OF TECHNOLOGY



FAKULTA INFORMAČNÍCH TECHNOLOGIÍ  
ÚSTAV POČÍTAČOVÝCH SYSTÉMŮ  
FACULTY OF INFORMATION TECHNOLOGY  
DEPARTMENT OF COMPUTER SYSTEMS

# ANONYMIZACE SPZ VOZIDEL ZACHYCENÝCH NA FOTOGRAFIÍCH

CAR LICENCE PLATE ANONYMIZATION

DIPLOMOVÁ PRÁCE  
MASTER'S THESIS

AUTOR PRÁCE  
AUTHOR

Bc. BARBORA SKŘIVÁNKOVÁ

VEDOUCÍ PRÁCE  
SUPERVISOR

Ing. MICHAELA ŠIKULOVÁ

BRNO 2016

## **Abstrakt**

## **Abstract**

## **Klíčová slova**

## **Keywords**

## **Citace**

Barbora Skřivánková: Anonymizace SPZ vozidel zachycených na fotografiích, diplomová práce, Brno, FIT VUT v Brně, 2016

# Anonymizace SPZ vozidel zachycených na fotografiích

## Prohlášení

Prohlašuji, že jsem tuto diplomovou práci vypracovala samostatně pod vedením Ing. Michaly Šikulové a uvedla jsem všechny literární prameny a publikace, ze kterých jsem čerpala. Další informace mi poskytl Ing. Adam Kolář ze společnosti Seznam.cz.

.....  
Barbora Skřivánková  
30. prosince 2015

## Poděkování

© Barbora Skřivánková, 2016.

*Tato práce vznikla jako školní dílo na Vysokém učení technickém v Brně, Fakultě informačních technologií. Práce je chráněna autorským zákonem a její užití bez udělení oprávnění autorem je nezákonné, s výjimkou zákonem definovaných případů.*

# Obsah

<b>1</b>	<b>Úvod</b>	<b>2</b>
<b>2</b>	<b>Anonymizace obrazových dat</b>	<b>3</b>
2.1	Osobní údaje a jejich ochrana . . . . .	3
2.2	Anonymizace . . . . .	4
2.3	Metody využívané v současnosti . . . . .	4
2.3.1	Manuální anonymizace . . . . .	6
2.3.2	Automatizovaná anonymizace . . . . .	6
2.4	Obrazová data . . . . .	6
2.4.1	Snímání fotografií . . . . .	7
2.4.2	Ukládání fotografií . . . . .	8
2.4.3	Sešívání fotografií . . . . .	8
2.4.4	Vyrovnávání fotografií . . . . .	8
2.4.5	Namapování na kouli . . . . .	8
<b>3</b>	<b>Neuronové sítě</b>	<b>10</b>
3.1	Biologický základ neuronových sítí . . . . .	10
3.2	Umělý neuron . . . . .	11
3.3	Neuronové sítě . . . . .	13
3.3.1	Topologie sítí . . . . .	13
3.3.2	Učení . . . . .	13
3.4	Hluboké neuronové sítě . . . . .	13
<b>4</b>	<b>Návrh</b>	<b>16</b>
4.1	Předzpracování dat . . . . .	16
4.1.1	Finetuning . . . . .	17
4.2	Detekce aut v obrázku . . . . .	17
4.3	Detekce SPZ ve vybrané části obrázku . . . . .	18
4.3.1	Detekce SPZ v obrázku s autem . . . . .	18
4.4	Rozmazání SPZ . . . . .	18

## Kapitola 1

### Úvod

## Kapitola 2

# Anonymizace obrazových dat

Anonymizace dat je v dnešní době velmi aktuálním tématem. Velmi intenzivně se na ní pracuje jak na úrovni datové, tak na úrovni anonymizace obrazových dat, která je také předmětem této práce. Pokud je společnost schopna zajistit kvalitní anonymizaci dat, která spravuje, nejen, že tím plní svoje zákonné povinnosti, může si tím také vylepšit svoje jméno v očích zákazníků a společností, se kterými spolupracuje.

Tato kapitola se blíže zabývá legislativním podtextem ochrany osobních údajů v sekci , dále potom v sekci / popisem pojmu anonymizace dat a v sekci / jsou popsány metody, které se k anonymizaci dat používají v součastnosti.

### 2.1 Osobní údaje a jejich ochrana

Ochrana osobních údajů v České republice představuje soubor práv a povinností, které se vztahují k uchovávání a zacházení s daty přímo se týkajícími dané fyzické osoby. Osobní údaje nemusí být vždy přímo identifikující danou osobu (jako je například rodné číslo, jméno a příjmení, adresa trvalého bydliště apod.). Za osobní údaje jsou považovány jakékoliv údaje přímo související se životem konkrétní nebo určitelné osoby. Může jít například o provozování koníčků, členství v politických stranách, účast na specifických událostech, návštěvy různých míst, velikost oblečení a podobně. Ochrana osobních údajů (ochrana osobních dat) je v České republice regulována zákonem č. 101/2001 Sb., o ochraně osobních údajů a o změně některých zákonů a dalšími právními předpisy.

Zákon rozlišuje osoby, které zpracovávají osobní údaje (správce osobních údajů) a osoby, jejichž data správci zpracovávají (subjekt osobních údajů). Správcům jsou zákonem ukládány především povinnosti, zatímco subjektům údajů jsou dána práva. Dodržování práv a povinností obou stran je v České republice kontrolováno prostřednictvím Úřadu na ochranu osobních údajů.

Základní ideou ochrany osobních údajů je ta, že osobní údaje jsou shromažďovány a zpracovávány za nějakým účelem. Každý účel vyžaduje jiný typ osobních údajů a také jiné množství takto zpracovávaných osobních údajů. Ve výše uvedeném zákoně byly pro bližší specifikaci těchto účelů zavedeny pojmy účel zpracování, prostředky zpracování, způsob zpracování, kategorie osobních údajů, kategorie subjektů údajů a kategorie příjemců. V těchto termínech je třeba zpracovávání osobních údajů popsat. [citace ze zakona, pod carou: vyklaď z <http://www.oou.cz/>]

V této práci se budu věnovat zpracovávání obrazového materiálu nasbíraného na veřejném prostranství. Vzhledem k tomu, že veřejné prostranství je vždy snímáno za běžného

dne, spolu s terénem, který je snímán, jsou nasnímáni i lidé a další objekty, které se v daném prostranství pohybují. Jak bylo řečeno dříve v této kapitole, veškeré informace, které mohou prozradit jakékoli údaje přímo související s životem dané osoby jsou považovány za osobní údaje. Z toho vyplývá, že i obrazový materiál nasnímaný na veřejném místě obsahující cizí osoby nebo automobily obsahuje osobní údaje a je třeba se věnovat způsobu jejich zpracování.

V dnešní digitální době máme k dispozici velké množství obrazových dat. V této práci se budu věnovat datům zachytávaným pro účely vizualizace prostoru z mapy nasbírané v rámci služby Panorama společnosti Seznam.cz. Tato data jsou sbírána prostřednictvím speciálně upravené panoramatické kamery, která je umístěna na střeše vozidla. Toto vozidlo při průjezdu zpracovávanou lokalitou snímá svoje okolí a pořízený obrazový materiál se poté zpřístupňuje široké veřejnosti. Publikování obrazového materiálu, na kterém se vyskytují osobní údaje jako jsou SPZ vozidel, obličeje kolemjdoucích a podobně je velmi citlivou záležitostí. Aby bylo minimalizováno riziko zneužití těchto údajů, byla zvolena možnost anonymizace.

## 2.2 Anonymizace

Anonymizovaná data jsou taková data, která nemohou vést přímo k identifikaci konkrétního člověka. Pokud jsou data obsahující osobní údaje anonymizována, přestávají podléhat přísným regulacím Zákona o ochraně osobních údajů a lze s nimi nakládat volněji.

Hranici, kdy jsou data už anonymizována nelze zcela jednoznačně definovat a anonymizaci je třeba pro každou specifickou skupinu dat posuzovat individuálně. Pouhé začernění jména v dokumentech malé firmy například nemusí vést k tomu, že konkrétní osoba nebude dle dalších vodítek v dokumentech identifikovatelná. Příklad toho, že stejná úroveň anonymizace nemusí mít vždy stejné výsledky může sledovat porovnáním obrázků 2.1 a 2.2. Oba obrázky jsou zpracovány stejným rozostřovacím filtrem. U SPZ na obrázku 2.1 by bylo dekódování původní poznávací značky automobilu

## 2.3 Metody využívané v současnosti

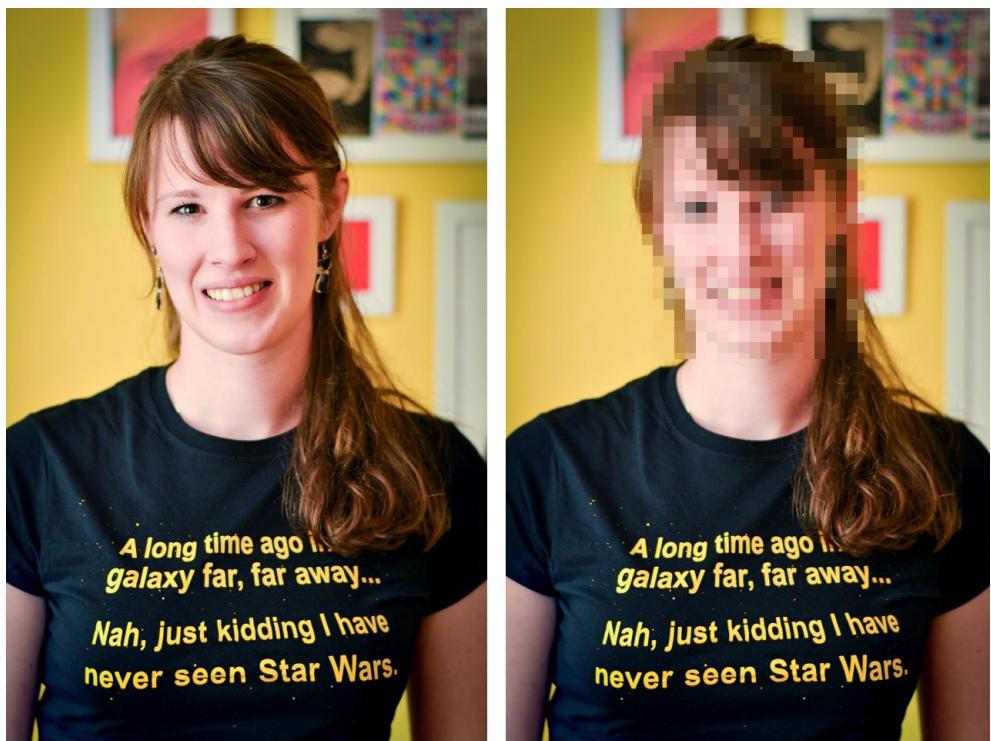
Datová anonymizace dosáhla v současné době uspokojivé úrovně. Úspěšně anonymizována jsou jak data v pdf dokumentech, tak v databázích. Datovou anonymizaci lze v dnešní době provádět plně automatizovaně prostřednictvím mnoha nástrojů jak komerčních, tak volně dostupných.

Anonymizace v obrazových datech zatím nedosáhla tak vysoké úrovně a to hned z několika důvodů: 1. Anonymizace v obrazových datech je velmi aplikačně specifická - není proto tak velký tlak na její vývoj 2. Anonymizace obrazových dat je výpočetně náročnější než anonymizace na úrovni datové 3.

Anonymizace obrazových dat sestává ze dvou částí: detekce části obrázku určené k anonymizaci a vlastního procesu anonymizace. Je zřejmé, že vlastní proces anonymizace už není výpočetně nijak náročný. Jedná se zpravidla o aplikaci rozostření, případně o přidání vrstvy, která plně překrývá anonymizované části obrázku. Problematická však je detekce části obrázku určené k anonymizaci.



Obrázek 2.1: Anonymizovaná SPZ vozidla.



Obrázek 2.2: Anonymizovaný obličej.



Obrázek 2.3: Problémy stávajícího řešení anonymizace SPZ v Panoramě. Chybně anonymizované nápisy nad obchody jsou na obrázku vyznačeny červenou barvou.

### 2.3.1 Manuální anonymizace

Po dlouhou dobu byla anonymizace obrazových dat potřeba většinou na malém objemu dat (například ve zpravodajství a podobně). V takovém případě je naprosto dostačující provádět výběr části obrázku, která je určena k anonymizaci manuálně.

Kvalita takto anonymizovaného obrázku je velmi dobrá, protože člověk přímo vidí výsledek a dokáže korigovat rozsah provedené úpravy tak, aby výsledný obrázek byl skutečně anonymní. Na svoje limity tato metoda však naráží při nárůstu množství anonymizovaných dat.

Pro představu při zpracovávání dat pro službu Panorama vzniknou každý snímací den 4TB obrazového materiálu z každého snímajícího vozidla. Takové množství dat už není v rozumném čase možné zpracovávat manuálně a tak je třeba vytvořit automatizovanou variantu.

### 2.3.2 Automatizovaná anonymizace

Automatizovaná anonymizace obrazových dat je zatím na počátku svého vývoje.

Eyedea anonymization - to se používá v Seznamu. TODO: zjistit jak to funguje a jaké jsou alternativy.

Zásadním problémem automatizované anonymizace, hlavně při anonymizaci SPZ vozidel, jsou chyby vzniklé při detekci SPZ. Ty jsou totiž často detekovány i na místech, na kterých se sice na fotografii vyskytuje text, nikoliv však SPZ viz obrázek ???. Při použití anonymizovaných dat pro službu Panorama je tento druh chyb nepřijatelný. Jde totiž o omezení jednoho z důležitých účelů služby Panorama. Uživatelům slouží hlavně pro lepší orientaci v terénu, který neznají. Pokud chce uživatel službu využít k rychlejšímu nalezení nějaké prodejny, je naprostě nežádoucí, aby v rámci automatické anonymizace SPZ vozidel byly anonymizovány i např. nápisy nad vstupy do obchodů a provozoven. V aktuálním stavu automatizované anonymizace je právě tato závada velmi častá. V této práci bude ukázáno, jakým způsobem se těmto chybám vyvarovat.

## 2.4 Obrazová data

Obrazová data byla dodána společností Seznam.cz a.s. V této sekci bude popsán způsob, jakým jsou obrazová data pro službu Panorama snímána, a jak jsou dále zpracovávána než se dostanou ke koncovému uživateli. Anonymizér, který je praktickým výstupem této



Obrázek 2.4: Automobil s 15 kamerami umístěnými na snímací hlavě na střeše.

práce je jen jedním článkem v sekvenci operací, která je nad každým zachyceným obrázkem provedena.

#### 2.4.1 Snímání fotografií

Fotografie jsou snímány speciálně upraveným vozem s 15 kamerami rozmístěnými na střeše. Tyto kamery zabírají  $360^\circ$  okolí snímacího automobilu. Způsob, jakým jsou kamery na střeše automobilu umístěny, je znázorněn na obrázku 2.4. Kamery jsou na snímací hlavě umístěny ve dvou řadách. První snímá dolní část výsledné fotografie - v té je umístěno šest kamer. V horní řadě je kamer umístěno 9 a snímají hlavní část obrazu. TODO:zjistit, jestli tam není ještě jedna kamera nahoře - to by bylo 6-8-1.

Při snímání se auto pohybuje rychlosťí 70 km/h. Snímání se provádí na všech 15 kamerách současně každé 3 metry. Aby bylo možné později fotografií co nejvíce přiblížit tomu, jak prostředí vnímá člověk, který se v něm pohybuje, při každém snímku se zaznamená ještě sada metadat. Tyto zahrnují

- číslo snímku
- celek (15 fotografií), do kterého snímek patří a poloha v něm
- datum snímání
- zeměpisná poloha snímacího auta v souřadnicích UTM 33
- $\omega$  – úhel náklonu automobilu v pravolevém směru
- $\varphi$  – úhel náklonu automobilu v předozadním směru
- $\kappa$  – odklon směru jízdy automobilu od severního směru, dále označováno pojmem *heading*
- TADY BY MOHL BÝT OBRÁZEK S JEDNOTLIVÝMA ÚHLAMA

Pro výpočet jednotlivých úhlů jsou k dispozici speciální senzory. Pro zaznamenávání headingu jsou na autě dvě vysoce přesné GPS jednotky, které na základě rozdílu svých GPS poloh dokáží přesně určit směr, kterým se snímací automobil pohybuje. Náklony ve všech směrech jsou měřeny pomocí inerciální jednotky a odometru.



Obrázek 2.5: 360° fotografie po vyrovnání horizontu.

#### 2.4.2 Ukládání fotografií

Při snímání každé 3 metry v rychlosti 70 km/h musí kamery pořizovat fotografie v plném rozlišení v rychlosti 6,48 fps. V tomto okamžiku tedy vzniká problém obrovského množství dat, která je třeba okamžitě zpracovávat. Ještě předtím, než jsou fotografie ve dvou kopiích uloženy na jeden ze čtyř 600GB SSD disků je třeba je převést z formátu *raw*, do kterého jsou pořizovány do formátu *jpeg*, ve kterém jsou ukládány a dále zpracovávány. Tento převod je prováděn na výkonné grafické kartě umístěné v kufru automobilu pomocí technologie *CUDA*.

Veškeré operace nad daty jsou prováděny v kufru automobilu, kam data ze střechy putují přes vysokorychlostní datové kabely. Každá z 15 kamer je s počítačem spojena pomocí své vlastní 1 Gbitové linky.

#### 2.4.3 Sešívání fotografií

Jakmile se data dostanou z terénu, začíná rozsáhlá množina operací, která je nad nimi prováděna. Jako první přijde na řadu sešívání snímků. Pomocí nástroje navrženého ve společnosti Seznam.cz je z 15 fotografií zachycených v jednom okamžiku vytvořena jediná širokoúhlá fotografie, nad kterou se nadále pracuje. V rámci sešívání fotografií jsou také odstraněny části auta, které se dostaly do záběru.

#### 2.4.4 Vyrovnávání fotografií

Na fotografií sešíté z 15 fotek je značně deformován horizont. Nyní tedy přichází na řadu vyrovnání horizontu zachyceného prostředí.

Toto se provádí...jak se to dělá? :D

Vzor výstupu z této operace je znázorněn na obrázku 2.5

#### 2.4.5 Namapování na kouli

Výsledný obrázek je následně namapován na kouli, na které už je zobrazován koncovému uživateli. Natočení této koule v prostoru dokáže dorovnat zakřivení, které vznikne vlivem snímání pod úhlem. V tomto okamžiku jsou využity zaznamenané úhly  $\omega$  a  $\varphi$ , jejichž aplikace zamezí uživatelskému pocitu *padání* obrazu.

## Ekvirektangulární projekce

Pro namapování obdélníkového obrazu na kouli je využita ekvirektangulární projekce (v literatuře též označována jako ekvidistantní projekce). Tato projekce využívá přepočet souřadnic dle vztahů 2.1 a 2.2, kde  $x$  a  $y$  jsou souřadnice na fotografii v rovině,  $\lambda$  značí zeměpisnou délku od centrálního poledníku v daném zobrazení,  $\varphi$  značí zeměpisnou šířku a  $\varphi_1$  je parametr rovnoběžek, který určuje rozsah skutečné projekce.

$$x = \lambda * \cos(\varphi_1) \quad (2.1)$$

$$y = \varphi \quad (2.2)$$

# Kapitola 3

## Neuronové sítě

Neuronové sítě jsou jednou ze tří hlavních podskupin vědního oboru soft computing. Dalšími problematikami, které tato vědní disciplína zkoumá jsou fuzzy systémy a evoluční algoritmy. Tato práce se věnuje hlubokým neuronovým sítím pracujícím nad obrázkovými daty. Neuronové sítě jsou uvedeny do širšího kontextu v této kapitole.

### 3.1 Biologický základ neuronových sítí

Při studiích v oborech biologie a biofyziky bylo během posledních několika dekád odhaleno mnoho principů, díky kterým se můžeme přiblížit pochopení funkce naší nervové soustavy a mozku. Základní stavební jednotkou lidského těla je buňka, základní stavební jednotkou nervové soustavy potom je *neuron*. Hlavní součásti neuronu jsou *dendrity*, *axony* a *tělo buňky (soma)*, jak je znázorněno na obrázku 3.1. Těchto neuronů se v lidské nervové soustavě nachází cca  $10^{11}$ .

**Dendrit** – Vstupní bod neuronu. Přes dendrity se do těla neuronu dostávají elektricko-chemické vzruchy, jejichž přenos je hlavní činností neuronu.

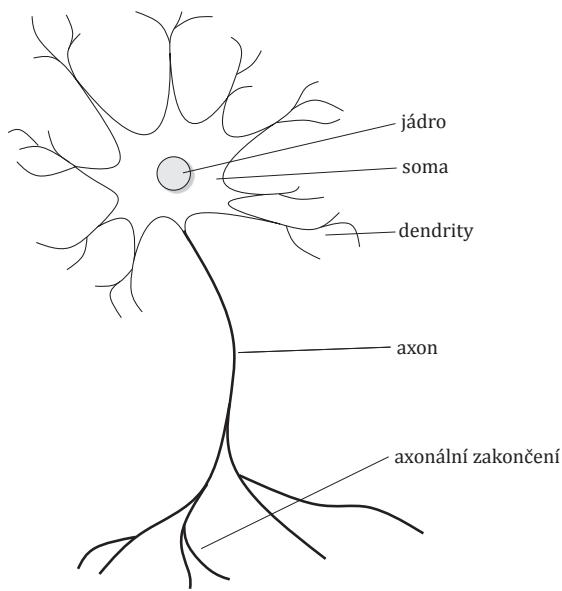
**Axon** – Část neuronu, která zajišťuje přenos vzruchů. Je ukončena *axonálním zakončením*, které je výstupním bodem neuronu a nachází se velmi blízko dendritu jiného neuronu.

**Synapse** – Spojení mezi dvěma neurony - přesněji mezi dendritem a axonálním zakončením. V dnešní době není aktivita mozku měřena v počtu neuronů, nýbrž právě v počtu synapsí.

**Neurotransmíter** – chemická látka, která zajišťuje přenos informací v mozku. V této práci budu mluvit o přenosu elektricko-chemického vzruchu v synapsi, ale neurotransmitery mají v nervové soustavě mnohem širší funkci.

**Soma** – tělo buňky. Sleduje, zda-li suma potenciálů přicházejících z jednotlivých dendritů nepřesáhla dný prah a pokud se tak stane, vygeneruje nový vzruch.

V okamžiku, kdy se v těle neuronu nashromáždí dostatečně velký potenciál, začne se šířit nervovým vláknem (axonem) až k axonálnímu zakončení. Tady přejde do dalšího neuronu. Velikost signálu přenášená z dendritu do těla neuronu závisí na síle impulzu sousedního neuronu, kterého se dendrit dotýká a také na *synaptické váze*. V těle neuronu se sečtou hodnoty signálů od všech aktivních dendritů. Pokud součet hodnot překročí jistý prah, soma



Obrázek 3.1: Schéma biologického neuronu. Na obrázku je zobrazeno *jádro*, které uchovává genetickou informaci buňky, *soma* je tělo buňky, *dendrity* jsou vstupní body neuronu, *axon* jsou výstupní výběžky tvořené axonovými vlákny a *axonální zakončení* jsou výstupní místa neuronu.

vygeneruje nový impulz a tím se vznich šíří do dalších neuronů. Bezprostředně po vytvoření pulzu se neuron stane na chvíli necitlivým. To má za následek generování nespojitého signálu, jehož frekvence se může pohybovat v rozmezí 0,1-100Hz.

### 3.2 Umělý neuron

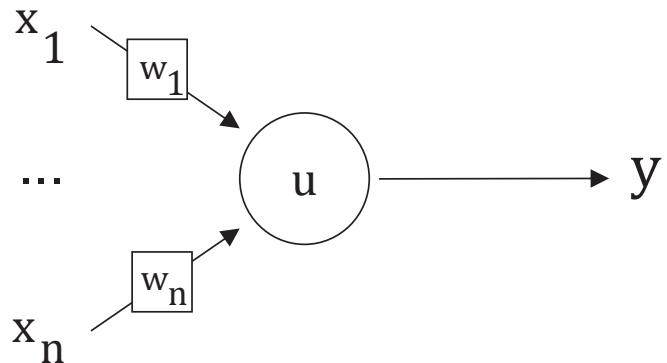
Princip biologického neuronu je napodobován umělým neuronem. Základní model umělého neuronu je zobrazen na obrázku 3.2, kde

$x_i$  je vstupní hodnota, která může být napojena na primární vstup nebo na výstup jiného neuronu.

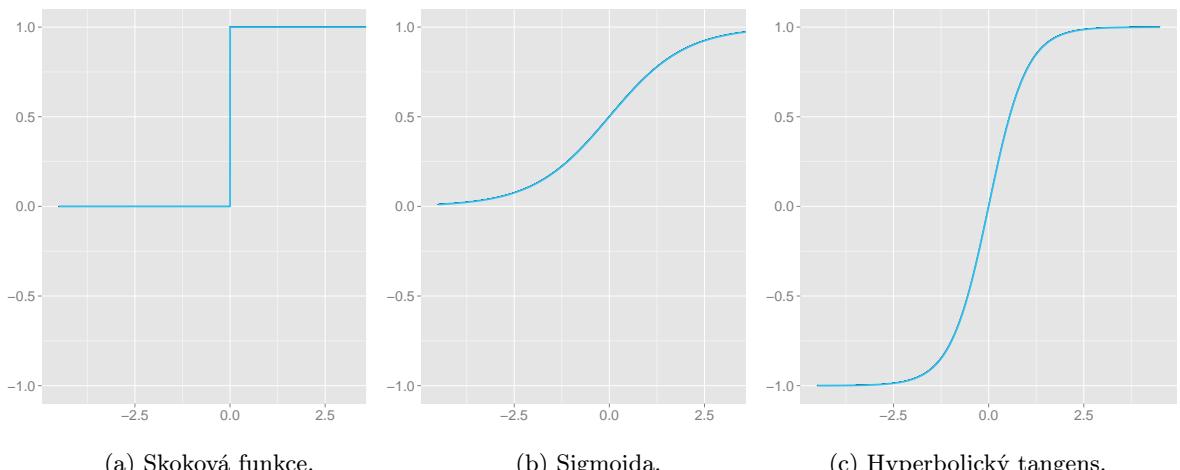
$w_i$  je váha propojení. Určuje jak moc bude konkrétní vstup  $i$  ovlivňovat výstup neuronu. Váhy se v průběhu výpočtu mění - probíhá *učení*, případně přes neměnnou váhu může být připojen tzv. *bias*.

$u$  je hodnota vnitřního potenciálu neuronu.

Jak je vidět na obrázku 3.2, na vstup umělého neuronu se přivádí vektor čísel, ty jsou pronásobena vektorem vah, které mají zpravidla malé hodnoty (většinou v intervalu  $< -1; 1 >$ , případně  $< -2; 2 >$ ), dále jsou nad nimi provedeny bázová a aktivační funkce (viz dále) a výstupem je jediné číslo. Umělý neuron je tedy matematická struktura, která zpracovává čísla a na výstupu podává jiná čísla.



Obrázek 3.2: Obecné schéma umělého neuronu, kde  $\vec{x} = (x_1, x_2, \dots, x_n)$  je vstupní vektor,  $u$  je vnitřní potenciál a  $y$  je výstupní hodnota.



(a) Skoková funkce.

(b) Sigmoida.

(c) Hyperbolický tangens.

Obrázek 3.3: Nejčastěji využívané aktivační funkce.

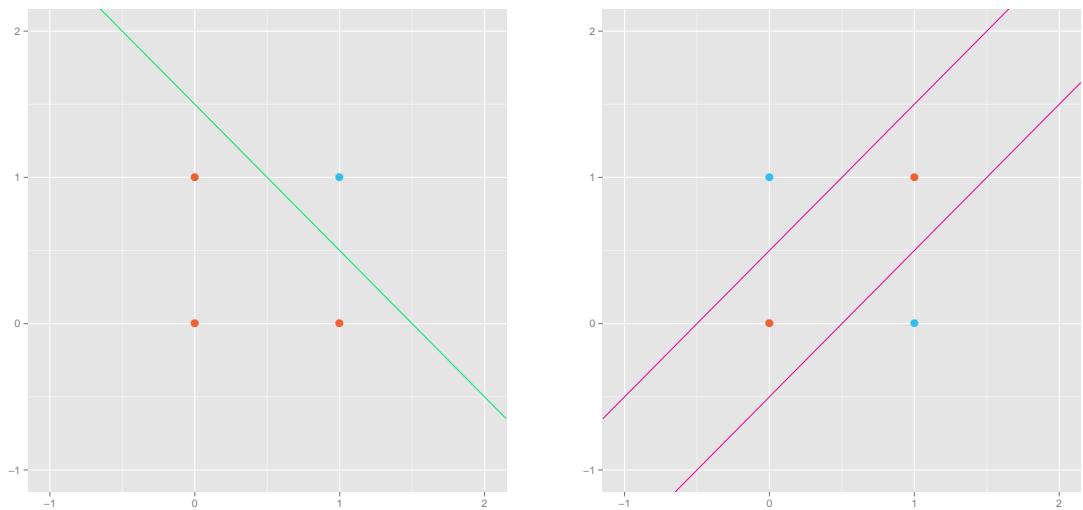
**Bázová funkce** - určuje způsob výpočtu vnitřního potenciálu  $u$  neuronu. Nejčastěji využívaná je lineární bázová funkce. Její vztah pro výpočet vnitřního potenciálu je uveden ve vztahu 3.1. Další z využívaných bázových funkcí je radiální bázová funkce - vztah 3.2.

$$u = \sum_{i=1}^n w_i \times x_i \quad (3.1)$$

$$u = \sqrt{\sum_{i=1}^n (w_i \times x_i)^2} \quad (3.2)$$

**Aktivační funkce** - též nazývaná *přenosová funkce*. Určuje způsob výpočtu výstupu neuronu z jeho vnitřního potenciálu. Tři nečastěji používané aktivační funkce jsou znázorněny na obrázku 3.3. Na ose x je vždy hodnota vnitřního potenciálu neuronu  $u$ , na ose y je potom výstupní hodnota neuronu.

Jednoduchý umělý neuron s jedním biasem a skokovou aktivační funkcí je v literatuře označován jako *perceptron*. Perceptron byl poprvé představen Frankem Rosenblattem v



(a) Lineárně separovatelná funkce AND.

(b) Lineárně neseparovatelná funkce XOR.

Obrázek 3.4: Problém lineární separovatelnosti.

roce 1958, matematický model neuronu však byl známý už od roku 1943 a princip činnosti biologického neuronu dokonce už od konce 19. století.

Pokud bychom chtěli perceptron využít ke klasifikaci vzorků do tříd, narazíme na jeho základní problém. Dokáže klasifikovat vzorky příslušící pouze dvěma třídám a tyto třídy musí být lineárně separovatelné. Váhy, které se upravují v průběhu učení perceptronu lze matematicky převést na vztah pro přímku v  $n$ -rozměrném prostoru. V rovině lze tedy lineární separovatelnost ilustrovat rozdělením na dvě poloroviny, kdy v jedné se nacházejí vzorky jedné třídy a ve druhé se nacházejí vzorky třídy druhé. Rozdíl mezi lineárně separovatelnými a lineárně neseparovatelnými problémy je znázorněn na obrázku 3.4. Mezi lineárně neseparovatelné problémy se řadí už i tak jednoduchý problém jako je XOR dvou hodnot (viz 3.4b). To značně omezuje obecnou využitelnost perceptronu a vzniká tak potřeba sdružování neuronů do neuronových sítí.

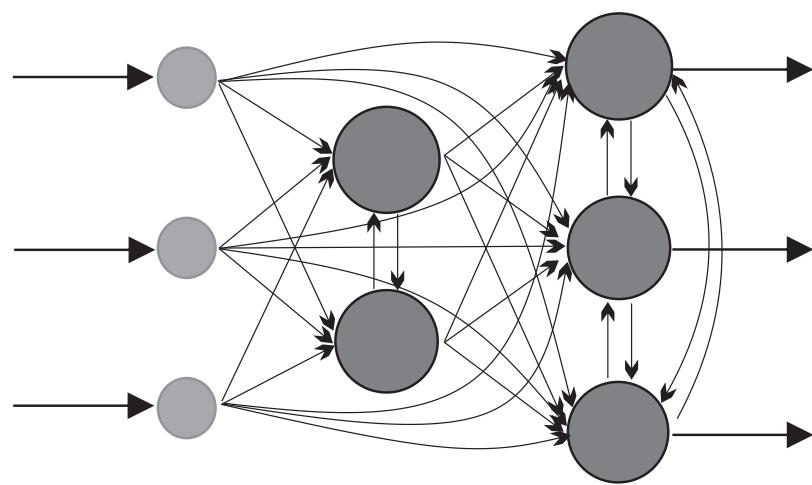
### 3.3 Neuronové sítě

Neuronové sítě vznikají spojením několika neuronů.

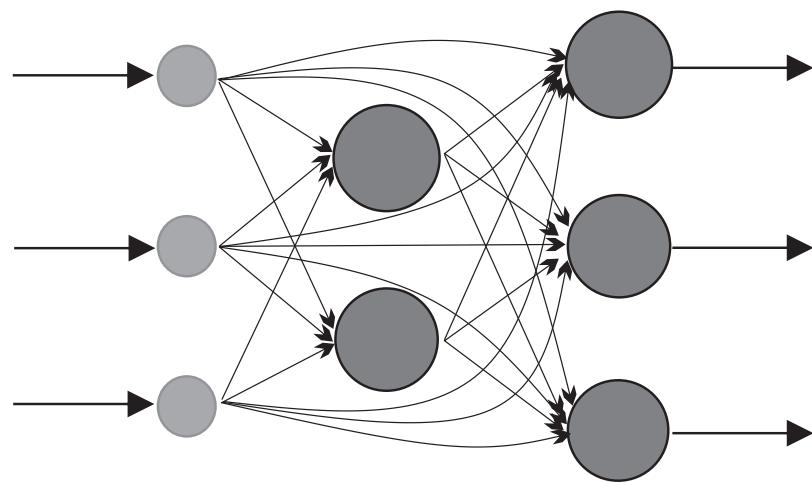
#### 3.3.1 Topologie sítí

#### 3.3.2 Učení

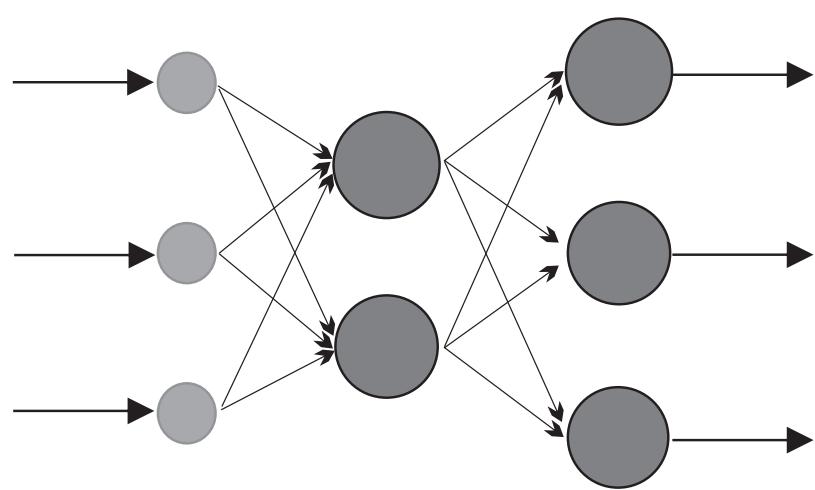
### 3.4 Hluboké neuronové sítě



Obrázek 3.5: Vrstvová síť. Výstup každého neuronu lze použít v aktuální nebo v každé další vrstvě. Neobsahuje zpětné vazby.



Obrázek 3.6: Acyklická síť. Výstup každého neuronu lze použít v některé z následujících vrstev.

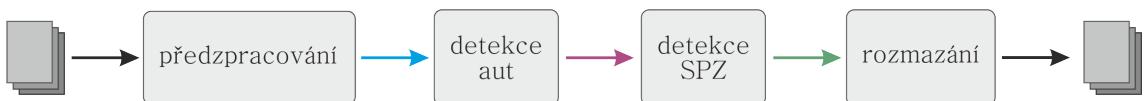


Obrázek 3.7: Dopředná síť. Výstup neuronu lze použít vždy jen v následující vrstvě.

# Kapitola 4

## Návrh

V této kapitole je popsán návrh implementovaného programu. Cílem této práce je vyrobit nástroj, který dokáže automaticky zpracovávat nafočené obrázky na vstupu a podávat anonymizované obrázky na výstupu. Práce s obrázky je rozdělena do čtyř základních fází znázorněných na obrázku 4.1, jejichž mechanismy budou v této kapitole podrobně popsány. Barevné šipky v obrázku 4.1 znázorňují jednotlivé mezivýsledky při zpracování a stejná barevná notace je použita i v dalších obrázcích této kapitoly.



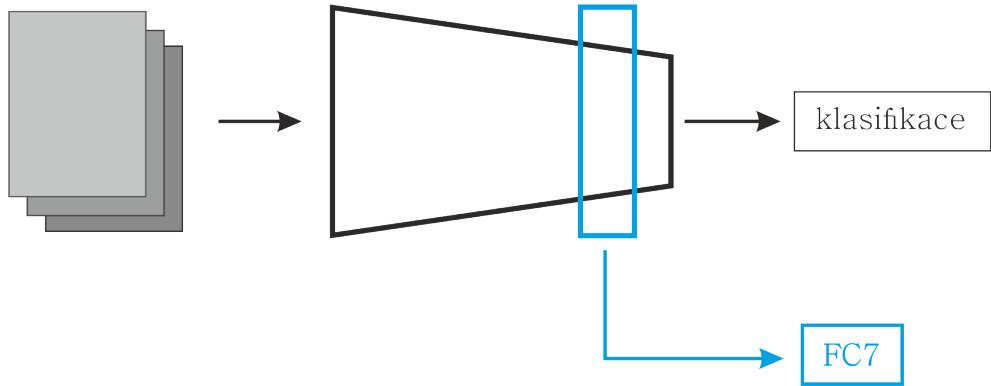
Obrázek 4.1: Základní struktura programu.

### 4.1 Předzpracování dat

Na primárním vstupu celého programu jsou přijímány fotografie nasnímané v rámci sběru dat pro službu Panorama. Všechny další fáze už však pracují nad čísly typu *double*, předzpracování dat tedy spočívá v reprezentaci celého obrázku pomocí číselného vektoru. Tento číselný vektor musí mít pro jednotlivé obrázky co nejlepší rozlišovací schopnost. Pokud je neuronová síť natrénována ke klasifikaci velkých dat do  $n$  tříd, jejím hlavním účelem je vyselektovat hodnoty, které jsou pro určování tříd podstatné - vytvořit tzv. *vektor rysů*. Tento vektor rysů, též *feature vector* je nejkondenzovanější informace z počátečních dat, výstupem z předzpracování dat je tedy právě feature vector.

K extrakci feature vectoru byla v této práci využita již naučená neuronová síť *Ilsvrc*, jež vznikla při příležitosti *ImageNet Large Scale Visual Recognition Challenge 2015* - odtud zkratka *Ilsvrc*. Tato výzva se koná každoročně a je zaměřena na algoritmy pro lokalizaci a detekci objektů v obraze a pak také na klasifikaci scény. Síť *Ilsvrc* byla naučena na množině obrázků *ImageNet*, která obsahuje více než 14 milionů obrázků rozřazených do 1000 kategorií.

Tato síť byla v rámci této práce pomocí *finetuningu* (viz část 4.1.1) optimalizována pro klasifikaci množiny obrázků bližší obrázkům, se kterými budu pracovat. Pro další použití není využíván primární výstup klasifikace (viz obrázek 4.2). Ze sítě je extraiován vektor rysů, jehož nejvíce informačně bohatá varianta se nachází v předposlední vrstvě sítě, která nese název *FC7*.



Obrázek 4.2: Schéma předzpracování dat.

#### 4.1.1 Finetuning

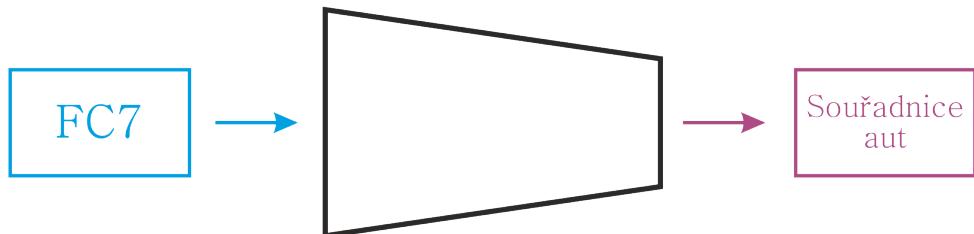
*Finetuning* je metoda využíváná v případě, že už máme úspěšně natrénovanou síť a chceme ji využít ke klasifikaci na podobná data. Standardně se na počátku tréninku neuronové sítě na nový typ vstupu všechny váhy inicializují náhodně. Pokud však máme k dispozici už síť naučenou na velké množině obrázků, můžeme namísto náhodné inicializace nové sítě inicializovat váhy nové sítě na výsledné váhy naučené sítě. Proces učení této sítě se potom nazývá *finetuning*. Ten lze provádět více způsoby. Nejznámějšími z nich jsou:

- Úpravou vah pouze v poslední vrstvě
- Přidáním několika nových vrstev do naučené neuronové sítě

Základním principem finetuningu je to, že do vah v naučené části sítě není příliš zasahováno. V případě úpravy vah pouze v poslední vrstvě jsou ostatní váhy striktně zachovány ve svojí původní podobě. V případě přidání nových vrstev do naučené sítě je tato celá zachována ve svojí původní podobě a učení probíhá pouze na nových vrstvách vzniklé sítě.

## 4.2 Detekce aut v obrázku

Neuronová síť provádějící detekci automobilů v obrázku je stěžejní částí této diplomové práce. Je to též její hlavní implementační část. Cílem je získat neuronovou síť, jež na vstupu dostane feature vector vytvořený v rámci předzpracování dat a na výstupu podá souřadnice části obrázku, ve které detekovala auto.



Obrázek 4.3: Schéma detekce aut v obrázku.

## 4.3 Detekce SPZ ve vybrané části obrázku



Obrázek 4.4: Schéma detekce SPZ ve vybrané sekci obrázku

### 4.3.1 Detekce SPZ v obrázku s autem

Možnosti provedení:

- Detektor hran
- Neuronka
- Něco vyššího

## 4.4 Rozmazání SPZ

Popsat blur algoritmy etc.

◦